

LABORATÓRIO 09: Arquitetura RAG Avançada (HNSW, HyDE e Cross-Encoders)

1. Objetivo do Laboratório

Implementar, em Python, um pipeline de *Retrieval-Augmented Generation* (RAG) de nível de produção.

2. Contexto do Problema

Vocês devem construir um assistente de busca em manuais médicos privados. Quando o paciente digita uma *query* coloquial e vaga (ex: "*dor de cabeça latejante e luz incomodando*"), a Similaridade de Cosseno pura falha, pois o "espaço vetorial das perguntas" é diferente do jargão técnico dos manuais (ex: "*cefaléia pulsátil e fotofobia*"). O sistema de vocês interceptar a pergunta, usar um LLM para gerar uma ponte semântica (HyDE), buscar rapidamente em um grafo hierárquico e refinar a precisão matemática antes de entregar os documentos à IA geradora.


3. Roteiro de Implementação (Passo a Passo)

Passo 1: Construção e Indexação do Grafo HNSW

- Crie um conjunto de dados simulado contendo pelo menos **20 fragmentos de manuais técnicos** (você pode gerar isso com IA, focando em jargões de TI, Direito ou Saúde).
- Utilize um modelo de *Embedding* (ex: text-embedding-3-small da OpenAI ou um modelo BERT da Hugging Face) para converter os 20 textos em vetores densos.
- Inicialize um banco de dados vetorial (como FAISS ou ChromaDB) configurando explicitamente um índice **HNSW**.
- **Tarefa Analítica:** No README.md, explique rapidamente como os hiperparâmetros de arquitetura do HNSW (M e ef_construction) afetam o consumo de memória RAM do servidor em comparação a uma busca *K-Nearest Neighbors* (KNN) exata.

Passo 2: Query Transformation (A Mágica do HyDE)

- Escreva uma função que receba uma *query* coloquial do usuário.



- Esta função deve fazer uma chamada ao LLM pedindo para ele alucinar uma resposta técnica (Documento Hipotético).
- Vetorize este **documento falso** gerado pelo LLM. Ele servirá como sua nova âncora geométrica no espaço vetorial.

Passo 3: A Busca Rápida (Retrieve via Bi-Encoder)

- Utilizando o vetor do Passo 2, faça uma busca de Similaridade de Cosseno no índice HNSW.
- Recupere os **Top-10** documentos mais próximos (o "funil largo"). Imprima o resultado desta etapa no console para comprovar a recuperação rápida.

Passo 4: O Filtro Fino (Re-ranking com Cross-Encoder)

- Importe um modelo *Cross-Encoder* da biblioteca sentence-transformers (ex: cross-encoder/ms-marco-MiniLM-L-6-v2).
- Passe a *query* original unida aos 10 documentos recuperados ([CLS] Query [SEP] Documento) pelo Cross-Encoder.
- Ordene os 10 documentos com base no novo *score* de atenção profunda.
- Imprima os **Top-3** documentos finais que sobreviveram ao funil e que seriam injetados no contexto do LLM.


4. Critérios de Avaliação e Contrato Pedagógico

O laboratório comporá a nota da P2 e seguirá rigorosamente as regras de integridade do Contrato Pedagógico.

4.1. Formato de Entrega e Versionamento:

- **Plataforma:** O código-fonte (arquivos .py ou .ipynb) deve ser submetido obrigatoriamente através de um repositório no **GitHub**. O link deve ser postado na plataforma iCEV Digital.
- **Versionamento:** A versão final a ser corrigida deve conter obrigatoriamente a tag ou release "**v1.0**".

4.2. Política de Integridade Acadêmica e Uso de IA:



- **Uso Permitido:** Vocês podem usar ferramentas de IA generativa para *brainstorming*, geração dos textos fictícios da base de dados e *templates* de código, seguida de revisão crítica.
- **Declaração Obrigatória:** É **obrigatório** inserir no README.md a seguinte nota: *"Partes deste laboratório foram geradas/complementadas com IA, revisadas e validadas por [Seu Nome]"*.
- **Proibição Severa:** Submeter códigos inteiros gerados pela IA sem entendimento prévio, ou "emprestar" o trabalho de um colega (mesmo alterando variáveis), configura quebra de contrato. A punição é a **nota 0 (zero)** na atividade e registro da ocorrência. A reincidência leva à reprovação imediata.

4.3. Política de Prazos e Atrasos:

- Trabalhos devem ser enviados até as **23h59** da data estipulada.
- 1 dia de atraso: penalidade contratual de **-20%** na nota.
- De 2 a 3 dias de atraso: penalidade contratual de **-50%** na nota.
- Mais de 3 dias de atraso: **Nota 0 (zero)**, exceto mediante atestado ou justificativa oficial.

